

张跃文 | Yuewen Zhang

AI Infra / Systems Engineer · z15000675672@gmail.com

<https://github.com/ywzhang1031>

个人简介

C++ / Linux 与端侧实时系统工程经验，负责无人机降落保护及硬件编码模块。中科院硕士，视觉语言模型与域泛化研究背景。当前通过推理测量、单设备训练与 Agent 运行时项目向 AI Infra 深入。

技术栈

系统工程（工作交付）：C++ / Linux / 多线程 / atomic / mutex / iceoryx · 零拷贝 IPC / RAII / 环形缓冲区

端侧 AI 与视觉（工作交付）：Horizon X5M / BPU / NV12 / YUV / OpenCV / H.265 硬件编码 / 模型 I/O 与后处理

LLM Infra（项目实践）：Python / PyTorch / HTTP / SSE / TTFT / TPOT / 负载生成与指标校验 / Apple Silicon / MPS

Coding Agent（项目实践）：TypeScript / React / 工具协议与权限 / JSONL / 事件回放 / Context / Compaction / DSH 插件

工作经历

影石 Insta360 · Antigravity | 2024.07 - 2026.06

感知导航 · 高性能计算工程师

无人机降落保护 | 已交付

降落保护模块开发与端侧模型集成。融合视觉、深度、ToF 与导航数据，识别水面、不适宜地形和障碍物，为飞控提供降落保护状态。

- 水体分割：按水面占比动态调整检测频率；近地场景分类：在 1.5 m 以下识别地形。
- 不同传感器独立缓存，定期清理过期数据；100 ms 是配对容差，不是算法运行耗时。
- 模式重置时递增 epoch，处理前后核对版本；弱光时输出 Invalid 与原因，避免错误视觉判断。

本人负责系统模块与端侧集成；模型量化、编译产物由算法同事提供。

多路视频编码系统 | 已交付

硬件编码封装、通道生命周期与录制逻辑。将多类型传感器图像按需接入硬件编码，支持循环录制、事故片段保护和实时码流发布。

- 按配置启用通道，避免所有编码器常驻；BGR / NV12、宽度对齐与双目拼接。
- Init / Encode 封装底层调用顺序；RAII 析构释放资源；配置驱动创建和销毁。
- 默认 5 个片段，总录制窗口 5 分钟；最多保护 3 个事故相关片段。

事故片段保护是覆盖策略，不等同于断电后的文件完整性保证。

教育经历

中国科学院 · 上海微系统所 | 2021 - 2024 | 硕士 · 域泛化与视觉语言模型

上海海事大学 | 2017 - 2021 | 本科 · 通信工程

项目实践与研究

公开项目与实验记录 · 以各项目说明中的环境和版本为准

LLM Inference Systems Lab | 开发中

独立设计负载、测量协议与分析流程。构建可追溯的 LLM 推理测量工具，明确请求边界、流式输出语义、错误统计与延迟指标。

- 区分首 token、逐 token 与端到端延迟；错误请求单独统计，保留原始测量记录；优先使用服务端 usage，避免将 SSE 事件数当成 token 数。

当前环境：Apple Silicon；重点验证协议与指标。公开版为闭环基线，Open-loop 与 HTTP 链路正在迭代。

github.com/ywzhang1031/llm-inference-systems-lab

nanochat 训练实践 | 阶段实验完成

基于上游框架的单设备训练实践。在 Apple Silicon 上运行 Dense GPT 基础训练，观察批量、序列长度和梯度累积如何影响训练过程。

- 每个实验完成 5,000 步；每步全局约 16,384 tokens，即各约 81.92M 训练 tokens；d6 序列长度 2,048；d12 为 512。

实验范围：基于上游 nanochat，在 Apple Silicon / MPS 上进行单设备 Dense GPT 基础训练。

github.com/karpathy/nanochat

My Agent | 开发中

独立实现轻量 Agent 运行时。围绕工具执行、权限审批、上下文管理与结构化事件，搭建小而可理解的 Agent 执行系统。

- 受约束的工具参数与执行入口；Plan / Build 模式与审批流程；处理中断、恢复与上下文压缩。

公开仓库提供运行时基线，结构化事件与回放能力持续在本地迭代。

github.com/ywzhang1031/my-agent

DSH Aside | 已发布版本

独立开发 Host / UI 插件并发布 npm 包。为 DeepSeek Harness 提供锚定选中文本的旁路对话，保留主线思路，支持独立历史与分支。

- 选区锚定与侧栏问答；独立会话与历史分支；封装为可安装 npm 包，验证干净环境安装。

v0.1.0 已发布；宿主兼容范围与安装步骤以仓库说明为准。

github.com/ywzhang1031/dsh-aside

DALSCLIP | 已发表

第一作者 · 方法与实验研究。围绕 CLIP 的域泛化开展提示学习研究，将可学习映射与域不变表征结合。

- 基于 CLIP 的视觉语言表征；提示映射与域不变学习；发表于 Image and Vision Computing (2025)。

性能结论应对应论文中的数据集、基线和评价协议。

Image and Vision Computing, 154, 105359 (2025)