

张跃文 | Yuewen Zhang

AI Infra Engineer · C++ / LLM Systems · z15000675672@gmail.com

<https://github.com/ywzhang1031>

个人简介

C++ / Linux 高性能系统工程背景，作为研发负责人推动无人机降落保护与多路视频编码从需求对齐、研发联调到产品上线，负责模型量化与端侧部署。电子信息硕士，具备视觉语言模型与域泛化研究经历；当前推进 LLM 推理测量、PyTorch 训练实践与 Coding Agent Runtime。

技术栈

C++ 高性能系统（工作交付）：C++ / Linux / 多线程 · atomic / mutex / iceoryx · 零拷贝 IPC / RAII / 有界缓冲区 / 性能分析 / 异步 I/O

模型量化与部署（工作交付）：地平线模型量化 / Horizon X5M / BPU / 模型 Runtime / Tensor I/O / NV12 / OpenCV / H.265 硬件卸载

LLM 推理与训练（项目实践）：Python / PyTorch / HTTP / SSE Streaming / TTFT / TPOT / E2E / Open-loop / Closed-loop / Pretraining / MPS

Coding Agent Runtime（项目实践）：Tool Calling / 权限控制 / Context / Compaction / JSONL / 事件回放 / TypeScript / React / DSH 插件扩展

工作经历

影石 Insta360 · Antigravity | 2024.07 - 2026.06

感知导航 · 高性能计算工程师

无人机降落保护 | 已交付

- 作为研发负责人，主导立项、产品需求对齐、架构研发与飞控联调，推动功能上线。
- 使用地平线工具链完成模型量化与 BPU 部署，组织多传感器时间对齐、推理及后处理。
- 以 epoch 处理跨模式过期结果；NV12 直输、异步 I/O 与门控优化，使指定工况单帧约 50-60 ms 降至 20 ms 以内。

多路视频编码系统 | 已交付

- 牵头需求拆解、模块研发与跨团队联调，交付兼容 13 类传感器图像的硬件编码管线。
- 封装 H.265 输入 / 输出队列与 RAII 资源管理，按需初始化通道，减少常驻资源开销。
- 实现 5 分钟循环录制、最多 3 个事故片段保护与动态预览切换，支持飞行回放和现场调试。

教育经历

中国科学院大学 · 中国科学院上海微系统与信息技术研究所 | 2021.09 - 2024.06 | 电子信息 · 硕士

微系统技术国家重点实验室

上海海事大学 | 2017 - 2021 | 通信工程 · 工学学士

项目实践与研究

公开项目与实验记录 · 以各项目说明中的环境和版本为准

模型架构（研究与论文研读）：Transformer / Attention · CLIP / ViT · 域泛化

推理框架（在研）：vLLM · KV Cache · PagedAttention · Continuous Batching

后训练管线（计划实践）：SFT / RL / GRPO / Evaluation

LLM Inference Systems Lab | 开发中

构建可追溯的 LLM 推理测量工具，明确请求边界、流式输出语义、错误统计与延迟指标。

- 区分首 token、逐 token 与端到端延迟；错误请求单独统计，保留原始测量记录；优先使用服务端 usage，避免将 SSE 事件数当成 token 数。

当前环境：Apple Silicon；重点验证协议与指标。公开版为闭环基线，Open-loop 与 HTTP 链路正在迭代。

github.com/ywzhang1031/llm-inference-systems-lab

nanochat · 大模型训练管线 | 阶段实验完成

基于 nanochat 完成 Dense GPT 单设备预训练 checkpoint，沿 “Pretraining / SFT / RL / GRPO / Evaluation” 扩展整条训练实践路线。

- 完成 d6 / d12 预训练 checkpoint，各 5,000 步、约 81.92M 训练 tokens，记录序列长度与有效 batch。
- 后续管线：SFT / RL / GRPO / Evaluation，按阶段补充实验与结果。

当前完成：单设备 Dense GPT 预训练实验；后续路线：SFT、RL / GRPO 与阶段评测。

github.com/karpathy/nanochat

My Agent | 开发中

围绕工具执行、权限审批、上下文管理与结构化事件，搭建小而可理解的 Agent 执行系统。

- 受约束的工具参数与执行入口；Plan / Build 模式与审批流程；处理中断、恢复与上下文压缩。

公开仓库提供运行时基线，结构化事件与回放能力持续在本地迭代。

github.com/ywzhang1031/my-agent

DSH Aside | 已发布版本

为 DeepSeek Harness 提供锚定选中文本的旁路对话，保留主线思路，支持独立历史与分支。

- 选区锚定与侧栏问答；独立会话与历史分支；封装为可安装 npm 包，验证干净环境安装。

v0.1.0 已发布；宿主兼容范围与安装步骤以仓库说明为准。

github.com/ywzhang1031/dsh-aside

DALSCLIP | 已发表

围绕 CLIP 的域泛化开展提示学习研究，将可学习映射与域不变表征结合。

- 基于 CLIP 的视觉语言表征；提示映射与域不变学习；发表于 Image and Vision Computing (2025)。

性能结论应对应论文中的数据、基线和评价协议。

Image and Vision Computing, 154, 105359 (2025)